

PROJEKT 8

MINI LAKEHOUSE FOR WEATHER DATA

Adam Błażejowski 198344

Mateusz Kuczerowski 197900

CEL PROJEKTU

Głównym celem projektu było zbudowanie kompletnego potoku danych (Data Pipeline) w chmurze AWS, realizującego architekturę klasy Data Lakehouse (Medallion Architecture).

Dodatkowym aspektem analitycznym była automatyzacja procesu pobierania surowych danych pogodowych z zewnętrznego interfejsu REST API, ich strukturyzacja, czyszczenie oraz finalne przygotowanie do celów raportowych.

ARCHITEKTURA

Projekt opiera się na usługach Amazon Web Services. Głównym magazynem danych jest usługa Amazon S3. Zastosowano logiczny podział na warstwy:

- **Warstwa Bronze:** Niezmienne archiwum (Single Source of Truth). Przechowuje surowe pliki JSON pobierane prosto z API.
- **Warstwa Silver:** Oczyszczona baza. Zawiera zwalidowane i zdeduplikowane dane przekonwertowane do wydajnego formatu Parquet.
- **Warstwa Gold:** Analityka. Przechowuje zagregowane podsumowania dzienne (Parquet), gotowe do odpytywania przez systemy BI oraz Amazon Athena.
- **athena-results/:** Folder techniczny na wyniki zapytań SQL.

STRUKTURA KODU

Aplikacja podzielona jest na wyspecjalizowane, modularne skrypty w języku Python:

- **ingestion.py:** Ekstrakcja danych. Autoryzacja tokenem, pobranie wyników z API w formacie JSON i wysyłka do warstwy Bronze z sygnaturą czasową.
- **transformation.py:** Przetwarzanie ETL. Oczyszczanie logów, walidacja i deduplikacja. Zapis przetworzonych danych jako pliki Parquet w warstwie Silver.
- **analytics.py:** Agregacja. Lokalny proces generowania warstwy Gold na podstawie danych Silver.
- **Skrypty SQL (Athena):** Instrukcje DDL/DML służące do tworzenia tabel analitycznych (CTAS) na podstawie plików na S3.
- **Konwersja Formatów:** Przejście z JSON do formatu kolumnowego Parquet, optymalizującego zapytania SQL.


PIPELINE (ETL)

Potok danych automatycznie pobiera surowe pomiary i archiwizuje je w AWS S3. W fazie transformacji (Silver) dane poddawane są restrykcyjnym mechanizmom:

Deduplikacja: Usuwanie powtórzeń z użyciem kluczy `station\_id` oraz `timestamp`.

Fizyczne Filtrowanie: Odrzucanie anomalii pomiarowych (outliers) na podstawie reguł `VALIDATION\_RULES`.

ANALIZA TEMPERATURY




Dane z warstwy Gold odpytywane za pomocą silnik **Amazon Athena** (tabela `daily_weather_summary`).

Wykres prezentuje dzienny trend średniej temperatury dla stacji referencyjnej GND_01.

Wizualizacja pozwala na szybką indentyfikację załamań pogody oraz okresów ocieplenia w badanym przedziale czasowym.

WERYFIKACJA OPADÓW



Weryfikacja całkowitych sum opadowych dla stacji GDN_01.

Słupki obrazują kumulację opadów z dokładnością do dóch miejsc po przecinku.

Wykres ten stanowi ostateczne potwierdzenie poprawności logiki agregującej w module analitycznym (ETL).

PODSUMOWANIE I OGRANICZENIA

- **Schema-on-read:** Architektura nie wymusza twardego schematu przy zapisie na S3. Struktura danych nakładana jest dopiero w locie przez Amazon Athena.
- **Brak automatyzacji metadanych:** Głównym ograniczeniem jest brak zastosowania AWS Glue Crawlers. Nowe partycje danych nie są automatycznie wykrywane w katalogu.
- **Manualna rekonfiguracja:** Pojawienie się nowych danych wymaga obecnie manualnego odświeżania tabel (polecenie `MSCK REPAIR TABLE`).
- **Brak orkiestracji (Scheduling):** Podobnie jak w referencyjnych rozwiązaniach, skrypty wymagają uruchamiania ręcznego, brakuje narzędzia typu Apache Airflow lub Cron.

KONIEC